

DETECÇÃO DE ATIVIDADES FRAUDULENTAS EM TRANSAÇÕES FINANCEIRAS UTILIZANDO INTELIGÊNCIA ARTIFICIAL

**Carlos Alberto Martins Soares Junior¹, Kaue Souza Pinto²
Marcelo Arantes³**

Aluno do Curso de Sistema de Informação – UGB
Docente/pesquisador do Curso de Sistema de Informação UGB

Resumo: Este trabalho tem como objetivo avaliar o desempenho de algoritmos de Inteligência Artificial (IA) aplicados à detecção de fraudes em transações bancárias, utilizando um conjunto de dados público, para isso, são empregadas técnicas de aprendizado de máquina, como métodos supervisionados a exemplo do Decision Tree, Random Forest e XGBoost, capazes de aprender padrões a partir de exemplos rotulados. Destaca-se a evolução da IA e seu papel transformador no contexto bancário. Diante do crescimento expressivo do número de transações digitais e da evolução das ameaças cibernéticas, é fundamental desenvolver soluções automatizadas que consigam detectar fraudes de forma ágil e precisa. A pesquisa busca demonstrar como técnicas de aprendizado de máquina podem identificar padrões anômalos e reconhecer comportamentos fraudulentos em operações financeiras digitais. Diante do crescimento expressivo das transações eletrônicas e da sofisticação das fraudes, torna-se essencial o desenvolvimento de métodos automatizados e eficientes de detecção. Foram empregados algoritmos de aprendizado supervisionados, como Random Forest, XGBoost e Decision Tree, comparando seus desempenhos com base em métricas como acurácia, precisão, recall e F1-score. Os resultados obtidos possibilitaram avaliar a eficácia das abordagens utilizadas, contribuindo para o aprimoramento de sistemas inteligentes de prevenção a fraudes no contexto bancário.

Palavras-chave: aprendizado de máquina; detecção de fraudes; fraudes financeiras; inteligência artificial; transações digitais

Abstract: This work aims to evaluate the performance of Artificial Intelligence (AI) algorithms applied to fraud detection in banking transactions, using a public dataset. To this end, machine learning techniques are employed, such as supervised methods like Decision Tree, Random Forest, and XGBoost, capable of learning patterns from labeled examples. The evolution of AI and its transformative role in the banking context is highlighted. Given the significant growth in the number of digital transactions and the evolution of cyber threats, it is fundamental to develop automated solutions that can detect fraud quickly and accurately. The research seeks to demonstrate how machine learning techniques can identify anomalous patterns and recognize fraudulent behavior in digital financial operations. Given the significant growth of electronic transactions and the sophistication of fraud, the development of automated and efficient detection methods becomes essential. Supervised learning algorithms, such as Random Forest, XGBoost, and Decision Tree, were employed, comparing their performance based on metrics such as accuracy, precision, recall, and F1-score. The results obtained made it possible to evaluate the effectiveness of the approaches used, contributing to the improvement of intelligent fraud prevention systems in the banking context.

Keywords: machine learning; fraud detection; financial fraud; artificial intelligence; digital transactions

INTRODUÇÃO

O crescimento exponencial das transações financeiras digitais tem proporcionado grande conveniência aos usuários, contudo resultou em um aumento significativo nas tentativas de fraude. Segundo a Federação Brasileira de Bancos (FEBABAN, 2025) o número de ataques cibernéticos e fraudes financeiras no Brasil aumentou em mais de 40% nos últimos dois anos, impulsionado pela digitalização dos serviços e pela facilidade de acesso a meios eletrônicos de pagamento. As fraudes financeiras representam um problema crescente no setor bancário moderno, gerando prejuízos significativos tanto para clientes quanto para instituições financeiras. Essas ocorrências afetam a confiabilidade dos sistemas digitais, prejudicam a imagem corporativa das instituições, e acarretam custos elevados relacionados à recuperação de valores, indenizações e investimentos adicionais em segurança da informação. Além disso, com o avanço da digitalização dos serviços bancários e o aumento das transações online, as tentativas de fraude tornaram-se mais sofisticadas, exigindo o uso de técnicas inteligentes e automatizadas de detecção.

Nesse contexto, surge a Inteligência Artificial (IA) como um mecanismo promissor para o aprimoramento dos sistemas de detecção de fraudes. Por meio de algoritmos capazes de aprender padrões complexos em grandes volumes de dados, a IA permite identificar comportamentos suspeitos com maior precisão e velocidade.

A escolha de utilizar Inteligência Artificial para detecção de fraudes se justifica pela necessidade de respostas mais rápidas e assertivas frente ao volume crescente de transações digitais e à sofisticação dos golpes. Métodos tradicionais, baseados apenas em regras fixas ou filtros estáticos, não conseguem acompanhar a dinamicidade e adaptabilidade dos fraudadores. Dessa forma, a adoção de modelos de Inteligência Artificial pode oferecer uma solução eficiente, escalável e autônoma, capaz de atuar em tempo real e com alto grau de precisão. Esta pesquisa tem como o objetivo desenvolver e avaliar modelos de Inteligência Artificial capazes de detectar fraudes financeiras em transações bancárias, comparando o desempenho entre abordagens supervisionadas, e realizar uma revisão sobre fraudes financeiras e técnicas de IA aplicadas à detecção de anomalias. Por meio da aplicação de um dataset público de transações bancárias, executando algoritmos de aprendizado de máquinas, bem como avaliar o desempenho através de métricas para identificar padrões relevantes que caracterizam comportamentos fraudulentos e analisar sua relevância prática para sistemas bancários reais.

REFERENCIAL TEÓRICO

A fraude pode ser compreendida como qualquer ação intencional com o objetivo de obter vantagem indevida por meio de engano, manipulação de informações, falsificação de dados ou violação de regras e sistemas. No contexto financeiro, refere-se a transações realizadas de forma ilícita com a finalidade de desviar recursos, ocultar informações, enganar instituições bancárias ou prejudicar clientes. Segundo Batista, Bruno e Ferreira (2021) as fraudes financeiras tornaram-se mais frequentes com o avanço das tecnologias digitais, em razão do crescimento das operações online, da facilidade de acesso remoto a contas e do grande volume de transações processadas diariamente, o que aumenta a superfície de ataque e dificulta a detecção manual. Essas práticas exploram vulnerabilidades técnicas e humanas, como falhas de autenticação, engenharia social, uso indevido de credenciais e manipulação de sistemas automatizados.

Os impactos das fraudes vão muito além das perdas monetárias. Elas afetam a reputação institucional, a confiança dos consumidores e a credibilidade do sistema financeiro, podendo gerar consequências legais e regulatórias severas. Por isso, a detecção precoce e automatizada dessas práticas é considerada essencial, especialmente em um cenário de alta digitalização dos serviços bancários. Um exemplo notável é o estudo de Whitrow (2008) que demonstrou o uso de modelos baseados em árvores de decisão e redes neurais artificiais para detectar fraudes em cartões de crédito, alcançando resultados superiores aos métodos baseados apenas em regras fixas. De forma semelhante Pozzolo e Caelen (2014) analisaram a eficácia de técnicas como Random Forest em bases de dados bancárias, concluindo que modelos combinados e o balanceamento de classes melhoram significativamente a taxa de detecção.

Essas iniciativas demonstram que o uso de Inteligência Artificial (IA) tem se mostrado um recurso promissor na identificação e prevenção de fraudes. A Inteligência Artificial é um campo da ciência da computação que busca desenvolver sistemas capazes de simular a capacidade humana de raciocinar, aprender, perceber e tomar decisões. Em síntese, IA é um conjunto de tecnologias que permite que os computadores aprendam, raciocinem e realizem várias tarefas avançadas e autônomas. De acordo com Russel e Norvig (2009), a IA pode ser compreendida a partir de quatro abordagens distintas: sistemas que pensam como humanos, sistemas que agem como humanos, sistemas que pensam racionalmente e sistemas que agem racionalmente.

Um dos principais ramos da Inteligência Artificial é o aprendizado de máquina (*Machine Learning*), que consiste em permitir que os sistemas aprendam automaticamente a partir dos dados, sem depender de programação explícita. Conforme Alpaydin (2020) o aprendizado de máquina é o campo que confere aos computadores a capacidade de aprender com a experiência, utilizando modelos estatísticos e computacionais para reconhecer padrões complexos e extrair conhecimento útil de grandes volumes de informações.

O aprendizado supervisionado é uma das formas mais comuns de aprendizado de máquina. Nessa abordagem, o modelo é treinado com exemplos rotulados, ou seja, dados de entrada acompanhados de suas respostas corretas para aprender a relação entre as variáveis e, posteriormente, realizar previsões em novos dados.

Durante o treinamento, o algoritmo ajusta seus parâmetros internos para minimizar os erros entre suas previsões e os valores reais, processo que ocorre de maneira iterativa até que o modelo atinja um nível aceitável de precisão. Esse tipo de aprendizado é amplamente utilizado em tarefas de classificação, nas quais o objetivo é atribuir uma categoria a uma nova instância com base em padrões aprendidos.

Entre os modelos utilizados neste estudo destacam-se o Random Forest, o XGBoost e o Decision Tree. O Random Forest é um método supervisionado baseado na combinação de várias árvores de decisão independentes, que juntas formam um modelo mais robusto e menos suscetível a erros de sobreajuste. O XGBoost, por sua vez, é uma técnica de *boosting* que constrói árvores de forma sequencial, aprimorando o desempenho do modelo a cada iteração e reduzindo gradualmente os erros das previsões anteriores. Já o algoritmo Decision Tree é um método de aprendizado supervisionado utilizado em tarefas de classificação e regressão. Ele funciona por meio de uma estrutura hierárquica de decisões, em que os dados são divididos em subconjuntos com base em atributos que melhor separam as classes. Esses modelos foram aplicados e comparados neste trabalho para avaliar sua eficácia na identificação de fraudes financeiras, considerando diferentes abordagens de aprendizado e cenários de desbalanceamento de dados.

Segundo Friederich (2021), o aprendizado de máquina utiliza modelos matemáticos e estatísticos para reconhecer padrões em grandes volumes de dados, identificando relações ocultas que seriam de difícil percepção por métodos tradicionais. Esses modelos são amplamente aplicados em áreas como reconhecimento de imagens, recomendações automatizadas, previsão de séries temporais e, especialmente, detecção de fraudes financeiras (RUSSELL & NORVIG, 2009).

De acordo com Alpaydin (2020), o aprendizado de máquina é tradicionalmente dividido em três categorias principais, a forma como o modelo interage com os dados e aprende com eles: aprendizado supervisionado, não supervisionado e por reforço, conforme sintetizado na Tabela 1.

Tabela 1 - Classificação dos tipos de aprendizados de máquina

Tipo de Aprendizado	Descrição	Exemplo de Aplicação
Supervisionado	O modelo é treinado com dados rotulados, aprendendo a mapear entradas para saídas conhecidas.	Detecção de fraudes, classificação de e-mails (spam/não spam).
Não supervisionado	O modelo analisa dados sem rótulos, buscando agrupar ou identificar padrões ocultos.	Segmentação de clientes, detecção de anomalias.

Por reforço

O modelo aprende por tentativa e erros, controle de robôs, erro, recebendo recompensas ou sistemas autônomos e penalidades conforme suas ações. otimização de estratégias.

Fonte: Elaboração própria.


O aprendizado supervisionado é uma das técnicas mais utilizadas em aprendizado de máquina e consiste em treinar um modelo a partir de dados rotulados, nos quais cada entrada possui uma saída correta associada. Durante o treinamento, o modelo aprende a relação entre essas informações para conseguir fazer previsões sobre novos dados. Conforme explicam Russell e Norvig (RUSSELL & NORVIG, 2009), esse processo é chamado de supervisionado porque o conjunto de dados atua como um “professor”, indicando as respostas esperadas. O modelo ajusta seus parâmetros de forma iterativa, reduzindo o erro entre suas previsões e os valores reais por meio de algoritmos de otimização, geralmente baseados em gradiente descendente.

O modelo Random Forest é um dos algoritmos mais utilizados em tarefas de aprendizado supervisionado, tanto para classificação quanto para regressão. Desenvolvido por Breiman (2001) ele se baseia na ideia de combinar o resultado de várias árvores de decisão para obter um modelo mais robusto, preciso e menos propenso a erros de sobreajuste.

Em vez de criar uma única árvore de decisão, o algoritmo constrói diversas árvores independentes, cada uma treinada com um subconjunto aleatório dos dados originais e das variáveis disponíveis. Esse processo de aleatoriedade — conhecido como método de amostragem *bootstrap*, faz com que cada árvore aprenda padrões diferentes, contribuindo para um resultado mais estável (Breiman, 2001).

Após o treinamento, cada árvore do Random Forest vota na classe de uma nova instância, e o modelo final adota a classe mais votada (ou a média, em casos de regressão). Essa combinação de múltiplas árvores aumenta a capacidade de generalização e torna o algoritmo mais robusto a ruídos do que uma árvore isolada. A Figura 1 representa esse processo, mostrando várias árvores treinadas com subconjuntos de dados diferentes e combinadas para produzir a predição final.

Figura 1 : Explicação do funcionamento do algoritmo Random Forest




Fonte: (RESEARCH GATE, 2025)

Segundo a documentação do Scikit-Learn (2025) e Louppe (2014), o Random Forest é um método eficiente e versátil, capaz de lidar com grandes volumes de dados e variáveis diversas, destacando-se pela resistência a ruídos, pela capacidade de trabalhar com dados desbalanceados e pela análise da importância das variáveis.

O XGBoost, por sua vez, é um método de *ensemble* baseado em gradiente boosting, no qual cada nova árvore é treinada para corrigir os erros das anteriores, aprimorando progressivamente a precisão do modelo. Conforme descrito por XGBoost (2025) e por Chen e Guestrin (2016) esse processo iterativo torna o algoritmo altamente eficaz em tarefas de classificação e regressão.

O princípio central do XGBoost é combinar múltiplos modelos fracos (árvores pequenas e simples) para formar um modelo forte e preciso. Cada árvore adicionada tenta compensar as falhas das anteriores, resultando em um conjunto final altamente otimizado (XGBOOST, 2025).

Figura 2 : Explicação do funcionamento do algoritmo XGBoost




Fonte: (RESEARCH GATE, 2025)

De acordo com a documentação oficial do Scikit-Learn (2025), o XGBoost é projetado para ser extremamente rápido, utilizando otimizações como paralelismo interno, cache otimizado de memória e tratamento eficiente de valores ausentes. Essas características fazem com que ele se destaque em aplicações que exigem grande volume de dados e respostas em tempo real.

A Decision Tree é um método de aprendizado supervisionado usado para classificação e regressão, estruturado como um fluxograma em que cada divisão representa um teste sobre um atributo e cada folha corresponde a uma previsão. Segundo Han, Kamber e Pei (2012) o modelo funciona dividindo repetidamente os dados em grupos cada vez mais homogêneos em relação à variável-alvo, até que um critério de parada seja atingido. Cada caminho da raiz até uma folha representa a sequência de decisões que leva à classificação final, como identificar se uma transação é fraude ou não.

Figura 3 - Explicação do Algoritmo Decision Tree



Fonte: (PROFIT, 2025)

Em termos de aplicação prática, as árvores de decisão oferecem vantagens significativas, como a facilidade de interpretação, já que o modelo pode ser visualizado graficamente, e a capacidade de lidar com dados categóricos e numéricos sem necessidade de normalização (TREE, 2025).

MATERIAIS E MÉTODOS

Este estudo foi conduzido com o propósito de desenvolver e avaliar um sistema inteligente para a detecção de fraudes em transações financeiras, utilizando técnicas de aprendizado de máquina. O processo metodológico foi estruturado de forma cronológica, desde a seleção e preparação dos dados até a implementação e validação do modelo em um ambiente simulado. Todos os procedimentos foram realizados em ambiente controlado e local, visando garantir a reprodutibilidade dos resultados.

O conjunto de dados utilizado neste estudo foi obtido na plataforma Kaggle, intitulado *Credit Card Fraud Detection Dataset* (CREDIT CARD FRAUD, 2021). Ele contém 284.807 transações financeiras, das quais 492 são classificadas como fraudulentas, representando cerca de 0,17% do total. O conjunto de dados é amplamente utilizado em pesquisas sobre detecção de fraudes, por refletir um cenário realista de desbalanceamento de classes, em que o número de transações legítimas é muito superior ao de transações fraudulentas.

As variáveis presentes nesse dataset estão descritas na Tabela 2, que apresenta os principais atributos e suas respectivas descrições, conforme disponibilizado na base de dados original.

Tabela 2: Atributos e descrições das variáveis do conjunto de dados *Credit Card Fraud Detection*

Atributo	Descrição
----------	-----------

Time	Tempo decorrido entre a primeira e a última transação registrada.
V1 – V28	Variáveis obtidas por transformações PCA para anonimização dos dados.
Amount	Valor da transação.
Class	Variável alvo (0 = legítima, 1 = fraude).

Fonte: Adaptado de Kaggle (2025)

O conjunto de dados original era altamente desbalanceado, com 284.807 transações, das quais apenas 492 (0,17%) eram fraudes, o que dificultaria o aprendizado dos modelos, que tenderiam a privilegiar as transações legítimas. Para reduzir esse desequilíbrio, foi realizada uma redução manual da classe majoritária, removendo aleatoriamente cerca de 98,4% das transações legítimas e mantendo todas as transações fraudulentas. Com isso, a proporção de fraudes foi ajustada para aproximadamente 10% do total, tornando o conjunto mais adequado ao treinamento dos algoritmos supervisionados. O processo, feito de forma manual e aleatória, garantiu controle sobre as amostras mantidas e preservou a integridade dos registros fraudulentos, evitando viés de seleção.

Após o balanceamento, o novo conjunto de dados passou a conter 4.920 registros, sendo 492 fraudes e 4.428 transações legítimas, resultando em uma proporção de 10% de fraudes, considerada adequada para os experimentos de detecção realizados neste estudo. Essa abordagem, conhecida como *undersampling* da classe majoritária, permitiu obter uma base de dados mais equilibrada, adequada para o treinamento e teste dos modelos supervisionados aplicados nesta pesquisa.

O pré-processamento teve como objetivo limpar, balancear e preparar os dados para o treinamento dos modelos. Inicialmente, foram removidas duplicatas e inconsistências utilizando o Pandas (2025) garantindo a integridade do conjunto. Em seguida, as colunas *Amount* e *Time* foram normalizadas com *StandardScaler*, padronizando suas escalas para melhor comparação entre variáveis.

Os experimentos foram realizados em ambiente local, utilizando Windows 10 Pro em um computador com processador AMD Athlon 3000G, 16 GB de RAM e arquitetura de 64 bits. Todo o processamento foi feito sem conexão externa, assegurando controle total sobre o ambiente e a reprodutibilidade dos resultados.

O estudo foi desenvolvido utilizando um conjunto de ferramentas escolhidas pela eficiência e ampla adoção na área de aprendizado de máquina. A linguagem principal foi o Python (2025), selecionada por sua versatilidade e grande ecossistema voltado à ciência de dados (MURPHY, KEVIN P., 2012). Ela foi empregada tanto no processamento e modelagem dos dados quanto na implementação dos algoritmos de Inteligência Artificial, garantindo integração entre todas as etapas do trabalho.

Entre as principais bibliotecas utilizadas, destaca-se a Scikit-learn (2025), responsável pela construção, treinamento e validação dos modelos, incluindo métricas e métodos de classificação. A Pandas (2025) foi utilizada para manipulação e limpeza dos dados, permitindo lidar eficientemente com grandes volumes de transações. A NumPy (2025) forneceu suporte para operações matemáticas e cálculos matriciais essenciais ao processamento. Por fim, a Matplotlib (2024) foi empregada na criação de gráficos e visualizações, auxiliando na análise comparativa dos resultados dos modelos.

Para a avaliação do desempenho dos modelos de aprendizado de máquina, foram utilizadas as métricas, acurácia, precisão, recall (ou sensibilidade) e F1-score. A acurácia, fórmula 1, representa a proporção total de previsões corretas realizadas pelo modelo, considerando tanto as classificações positivas quanto negativas

$$\text{Acurácia} = \quad (1)$$

A precisão, fórmula 2, indica a proporção de transações previstas como fraudulentas que realmente correspondem a fraudes.

$$\text{Precisão} = \quad (2)$$

O recall, fórmula 3 mede a proporção de fraudes reais que o modelo conseguiu identificar corretamente.

$$\text{Recall} = \quad (3)$$

O F1-score, fórmula 4, é a média harmônica entre a precisão e o recall, fornecendo uma visão equilibrada do desempenho do modelo, especialmente útil em bases de dados altamente desbalanceadas, como é o caso do conjunto de transações bancárias analisado neste estudo.

$$\text{F1-Score} = 2x = \quad (4)$$

Os valores VP, VN, FP e FN representam os possíveis resultados de um modelo de classificação: VP ocorre quando uma instância positiva é identificada corretamente; VN quando uma instância negativa é prevista corretamente; FP quando o modelo classifica como positiva uma instância que é negativa; e FN quando uma instância positiva é incorretamente classificada como negativa.

RESULTADOS

A redução e reorganização do conjunto de dados resultou em um dataset final com 4.920 registros, sendo 492 fraudes e 4.428 transações legítimas, proporção necessária para mitigar o desbalanceamento extremo presente na base original. Essa etapa foi essencial para evitar que os modelos priorizassem a classe majoritária e, consequentemente, apresentassem desempenho artificialmente elevado, porém incapaz de identificar fraudes de forma eficaz. Além disso, a normalização das variáveis garantiu que todos os atributos operassem na mesma escala, evitando distorções nos cálculos internos dos algoritmos e proporcionando um treinamento mais estável e consistente. Esses procedimentos, portanto, foram fundamentais para assegurar a qualidade do aprendizado e a confiabilidade dos resultados obtidos.

Os algoritmos Random Forest, XGBoost e Decision Tree foram executados de forma independente, respeitando os mesmos parâmetros de divisão dos dados, com o objetivo de comparar o desempenho de cada técnica no reconhecimento de transações fraudulentas. As métricas utilizadas para avaliação acurácia, precisão, recall e F1-score permitiram medir a capacidade de acerto global, o grau de exatidão nas previsões positivas, a sensibilidade do modelo e o equilíbrio entre precisão e recall, respectivamente.

A Tabela 3 apresenta o resumo dos resultados obtidos para cada algoritmo, destacando o desempenho de forma quantitativa.

Tabela 3 – Resultados obtidos pelos algoritmos

Modelo	Acurácia	Precisão	Recall	F1-Score
Random Forest	98,30	98,43	84,46	90,91
XGBoost	98,10	96,15	84,46	89,93
Decision Tree	97,36	86,09	87,84	86,96

Fonte: Elaboração Própria


Com apoio da biblioteca Matplotlib (2024), foi criado um gráfico comparativo, figura 4 das métricas, facilitando a visualização do desempenho dos modelos. O gráfico mostrou que o Random Forest obteve os melhores resultados em acurácia, precisão e F1-score, enquanto o Decision Tree apresentou maior recall, indicando maior sensibilidade para detectar fraudes, porém com menor precisão.

Figura 4 - Gráfico de comparação das métricas dos modelos

Fonte: Elaboração própria.

Além disso, foram geradas as matrizes de confusão para cada algoritmo, permitindo observar diretamente o comportamento dos modelos em relação a falsos positivos e falsos negativos. Os resultados mostraram que, o Random Forest apresentou o menor número de falsos positivos, conforme a figura 5, confirmando sua alta precisão.


Figura 5 - Matriz de Confusão Random Forest



Fonte: Elaboração própria.

O Decision Tree apresentou o menor número de falsos negativos, apresentado na figura 6, reforçando seu melhor recall entre os modelos.


Figura 6 - Matriz de Confusão Decision Tree



Fonte: Elaboração própria.

E afirmado na figura 7, o XGBoost apresentou um desempenho equilibrado entre os dois cenários, aproximando-se dos resultados do Random Forest.

Figura 7 - Matriz de Confusão XGBoost



Fonte: Elaboração própria.

Os resultados demonstraram que todos os modelos alcançaram elevados níveis de acurácia, superiores a 97%, indicando que a maior parte das transações foi corretamente classificada. Entre eles, o Random Forest apresentou o melhor desempenho geral, com 98,3% de acerto total, superando o XGBoost em cerca de 0,2 pontos percentuais e o Decision Tree em aproximadamente 1%.

No código, foi possível identificar aspectos importantes do processo, como a etapa de normalização, que se mostrou fundamental para garantir que todas as variáveis do conjunto de dados contribuíssem de forma equilibrada para o treinamento do modelo, conforme ilustrado na Figura 8.

Figura 8 - Código para a normalização dos dados

```
# Normalização
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

Fonte: Elaboração própria.

O *loop*, ilustrado na figura 9, treina cada modelo com os dados de treino e, em seguida, gera as previsões de classe (*y_pred*) e as probabilidades (*y_proba*).

Figura 9 - Código para treinamento dos modelos

```
for nome, modelo in modelos.items():  
    print(f"\nTreinando modelo: {nome}...")  
    modelo.fit(X_train, y_train)
```

Fonte: Elaboração própria.

Dessa forma, após a etapa de normalização dos dados e o subsequente treinamento dos algoritmos, procedeu-se ao cálculo das métricas de desempenho, permitindo avaliar de forma objetiva a capacidade de cada modelo em identificar transações, como demonstra a figura 10.

Figura 10 - Cálculo das métricas de desempenho

```
# Métricas  
acc = accuracy_score(y_test, y_pred)  
prec = precision_score(y_test, y_pred)  
rec = recall_score(y_test, y_pred)  
f1 = f1_score(y_test, y_pred)
```

Fonte: Elaboração própria.

De modo geral, todos os algoritmos apresentaram desempenho satisfatório e consistente na detecção de fraudes financeiras, as métricas bem como as matrizes de confusão, confirmam que as técnicas aplicadas foram eficazes na classificação das transações, demonstrando que as técnicas aplicadas foram capazes de reconhecer padrões relevantes de comportamento fraudulento e distinguir de forma eficiente as transações legítimas das fraudulentas, validando a eficácia do processo experimental desenvolvido neste estudo.

DISCUSSÃO

Os resultados deste estudo confirmam que algoritmos de aprendizado de máquina supervisionados conseguem identificar, com boa precisão, padrões que indicam fraudes em transações financeiras. Mesmo depois de balancear as classes do conjunto de dados, os modelos continuaram apresentando um bom estável, mostrando que funcionam bem mesmo quando há muita diferença entre a quantidade de transações legítimas e fraudulentas.

A análise mostrou que, na base original extremamente desbalanceada (0,17% de fraudes), os modelos tiveram desempenho inferior por priorizarem a classe majoritária. O Random Forest ainda seria o mais consistente, mas com mais falsos negativos; o XGBoost teria sensibilidade um pouco melhor, porém métricas gerais mais baixas; e o Decision Tree sofreria a maior queda de desempenho devido ao forte viés. Já na base balanceada, todos os modelos apresentaram melhorias expressivas, especialmente em recall e F1-score, confirmando a importância do ajuste das classes. Nesse cenário, o Random Forest obteve os melhores resultados, seguido de perto pelo XGBoost, enquanto o Decision Tree manteve maior variação e menor precisão, reforçando suas limitações frente aos métodos ensemble. Apesar disso, destaca-se que os testes foram feitos em ambiente controlado e com um único método de balanceamento, sugerindo a necessidade de estudos futuros com técnicas adicionais.

CONSIDERAÇÕES FINAIS

Este trabalho teve como objetivo investigar o uso de algoritmos de aprendizado de máquina supervisionados na detecção automatizada de fraudes financeiras em ambientes bancários digitais. Os resultados obtidos mostraram que todos os modelos foram capazes de identificar padrões associados a transações suspeitas, com destaque para o Random Forest, que apresentou o melhor desempenho entre as métricas analisadas. O XGBoost também demonstrou desempenho competitivo, enquanto o Decision Tree foi o modelo com maior instabilidade, refletindo sua limitação em comparação aos métodos ensemble.

A pesquisa evidencia o potencial das técnicas de Inteligência Artificial na segurança financeira, demonstrando que modelos supervisionados podem oferecer alta precisão, rapidez na análise e capacidade de adaptação a diferentes cenários. Além disso, ficou claro que procedimentos de pré-processamento e balanceamento de classes são determinantes para o sucesso dos modelos, especialmente em bases com forte desproporção entre transações legítimas e fraudulentas.

Como direções para trabalhos futuros, recomenda-se explorar métodos de balanceamento automatizados que preservem melhor a distribuição original dos dados, aplicar validação cruzada e otimização de hiperparâmetros para maior robustez dos modelos, e realizar testes em tempo real, utilizando fluxos contínuos de dados para simular ambientes bancários reais.

Portanto, o estudo confirma que a integração entre aprendizado de máquina e análise de transações financeiras é um caminho promissor para o desenvolvimento de sistemas inteligentes de prevenção a fraudes, contribuindo para o fortalecimento da segurança digital e para a modernização das práticas de monitoramento no setor financeiro.

REFERÊNCIAS

- AGARWAL, C. C. (2017). *Outlier Analysis*. New York: Springer.
- ALPAYDIN, E. (2020). *Introduction to Machine Learning*. The MIT Press.
- BATISTA, Bruno; , Jéssica FERREIRA. (2021). *A detecção de fraudes financeiras no contexto da transformação digital: desafios e soluções baseadas em Inteligência Artificial.*, p. 150.
- Breiman, L. (Outubro de 2001). Random Forests. *Machine Learning*. 45, p. 32.
doi:<https://doi.org/10.1023/A:1010933404324>

- Chen, T. (2016). XGBoost: A Scalable Tree Boosting System. *XGBoost: A Scalable Tree Boosting System*.
- CHEN, T., & GUESTRIN, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. San Francisco: ACM.
- CREDIT CARD FRAUD. (2021). Acesso em 04 de novembro de 2025, disponível em Kaggle: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>
- Fei Tony Liu, K. M. (01 de 03 de 2012). *Isolation-Based Anomaly Detection*, p. 39. doi:<https://doi.org/10.1145/2133360.2133363>
- FREBABAN. (2025). Acesso em 2025, disponível em Frebaban: <https://portal.febraban.org.br/>
- Friederich, P. (14 de 04 de 2021). *Scientific intuition inspired by machine learning-generated hypotheses*.
- GOODFELLOW, I., BENGIO, Y., & COURVILLE, A. (2016). *Deep Learning*. Cambridge: MIT Press.
- Han, J. (2011). *Data Mining: Concepts and Techniques*.
- HAN, J., KAMBER, M., & PEI, J. (2012). *Data Mining: Concepts and Techniques*. San Francisco: Morgan Kaufmann.
- LOUPPE, G. (2014). *Understanding Random Forests: From Theory to Practice*. Fonte: <https://arxiv.org/abs/1407.7502>
- Matplotlib. (2024). *Matplotlib*. Fonte: Matplotlib: <https://matplotlib.org/>
- Medium. (06 de 01 de 2024). Fonte: standardization-and-normalization-techniques-in-machine-learning: <https://medium.com/@vinodkumargr/07-standardization-and-normalization-techniques-in-machine-learning-standardscaler-3890a89bddbf>
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. The MIT Press.
- MURPHY, KEVIN P. (2012). *Machine Learning: A Probabilistic Perspective*. Cambridge: MIT Press.
- NOGALHA DE LIMA, J. D., & A. K. (25 de 09 de 2023). *A Inteligência Artificial na educação: as implicações no futuro do trabalho docente*, p. 12.
- NumPy. (2025). Acesso em 2025, disponível em NumPy: <https://numpy.org/>
- PANDAS. (04 de 11 de 2025). Fonte: Pandas: <https://pandas.pydata.org/>
- PEDREGOSA, F. e. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, pp. 2825–2830.
- POZZOLO, A., & CAELEN, O. (2014). Learned lessons in credit card fraud detection from a practitioner perspective. (E. S. Applications, Ed.) p. 4928. doi: 10.1016/j.eswa.2014.02.026
- PROFIT. (2025). Fonte: <https://www.profit.co/blog/project-management/how-to-use-decision-tree-analysis-to-make-confident-choices/>
- Python. (2025). Acesso em 2025, disponível em Python: <https://www.python.org/>

- RESEARCH GATE. (2025). Fonte: Research Gate:
https://www.researchgate.net/figure/Illustration-of-random-forest-trees_fig4_354354484
- RESEARCH GATE. (2025). Fonte: Research Gate:
https://www.researchgate.net/figure/Simplified-structure-of-XGBoost_fig5_381857634
- RUSSELL, S. J., & NORVIG, P. (2020). *Artificial Intelligence: A Modern Approach*. Boston: Pearson.
- RUSSELL, S., & NORVIG, P. (2009). *Artificial Intelligence: A Modern Approach*. Pearson.
- SCIKIT-LEARN. (2025). *Scikit-Learn*. Acesso em 03 de 11 de 2025, disponível em Scikit-Learn: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html?utm_source=chatgpt.com
- TREE, D. (2025). *DECISION TREE*. Acesso em 14 de 11 de 2025, disponível em DECISION TREE: <https://scikit-learn.org/stable/modules/tree.html>
- WHITROW, Christopher. (30 de Julho de 2008). Transaction aggregation as a strategy for credit card fraud detection. *Data Mining and Knowledge Discovery*, p. 55.
- XGBOOST. (2025). Acesso em 14 de 11 de 2025, disponível em XGBOOST: <https://xgboost.readthedocs.io/en/stable/>